

WDC 부산 2028 디지털 플랫폼 & AI 챗봇 구축 구현방안·서버·AI모델·비용 종합 답변

공식 웹사이트 지식기반형 AI 챗봇 개발계획서와 시민참여 공공디자인 진단시스템 운영서버 견적을 근거로, 구현방안·서버 스펙 및 비용·AI 모델 선정·사용량별 가격 시나리오에 대한 답변을 정리합니다.

수신 부산디자인진흥원 원장님·담당자 님	발신 사업 수행사 (부산인터넷방송국 / 스마트어플)	작성일 2026. 07. 09.
관련 문서 AI 챗봇 개발계획서(2026.7) 운영서버 견적서 PIBS202606- 043		

1 답변 개요

OVERVIEW

본 답변서는 발주기관 검토 편의를 위해 아래 **4개 질의 항목**을 하나의 문서로 정리한 것입니다. 모든 기술 방안은 CSAP 인증 공공기관용 클라우드 운영과 출처 연계형(RAG) 답변 구조를 전제로 합니다.

- ① **디지털 플랫폼 + AI 챗봇 구현방안** — 지식기반형 RAG 아키텍처, 출처 연계, CMS 연동, 개인정보·보안 (2장)
- ② **서버 스펙 및 비용** — 클라우드형 / 독립서버형 2개 옵션의 사양·연간 비용 비교 (3장)
- ③ **AI 모델 선정** — 공공 클라우드 LLM / 자체 호스팅 sLLM / 글로벌 상용 API 비교 및 권고 (4장)
- ④ **사용량·이용자별 가격 예상 시나리오** — 운영 상태별 월 비용과 인터뷰 1건당 원가 추정 (5장)

챗봇은 단순 FAQ 응답기가 아니라, 발주기관이 승인한 공식 콘텐츠·정책자료만을 근거로 **검색·요약·추천하고 모든 답변에 출처를 연계**하는 지식기반형 AI 안내 시스템으로 구현합니다. LLM이 자체 지식으로 임의 생성하는 것을 구조적으로 차단합니다.

2.1 시스템 4계층 구성

CSAP 인증 공공 전용 존(VPC) 내부에 4계층 + 전 구간 보안 계층으로 구성합니다.

프론트엔드

웹사이트 임베드 반응형 챗봇 위젯(답변 본문 + 출처 카드, 국·영문), CMS 관리자 콘솔

애플리케이션

대화·세션 관리, 입력 가드레일(PII 탐지·마스킹), RAG 오케스트레이터, 답변 검증·출처 연계

AI 모델

임베딩(BGE-M3)·리랭커(Cross-Encoder) 자체 구동 + 답변 생성 전용 LLM (4장 참조)

데이터

Vector DB(공개범위 필터)·RDB(메타·버전·비식별 로그)·객체 스토리지, 인덱싱 파이프라인

보안 계층

WAF·DDoS 방어·전 구간 TLS 1.3, RBAC·관리자 2FA·IP 제한, 저장 암호화·감사 로그 (전 구간 적용)

2.2 RAG 답변 생성 파이프라인

사용자 질의는 7단계를 거치며, 마지막 검증 단계에서 신뢰도 기준을 통과한 경우에만 정상 답변이 제공됩니다. 미달 시 **답변 제한 안내문**으로 분기됩니다.

STEP 1

입력 가드레일

개인정보·민감정보 실시간 탐지·마스킹, 부적절 질의 차단

STEP 2

질의 이해

카테고리 분류 + 문맥 반영, 질의 재작성

STEP 3

하이브리드 검색

키워드(BM25) + 벡터 검색, 공개범위 필터 강제

STEP 4

융합·리랭킹

RRF 융합 후 Cross-Encoder로 상위 근거 선별

STEP 5

근거 컨텍스트

출처 메타데이터와 함께 LLM 입력 구성

STEP 6

LLM 답변 생성

근거 내 내용만 생성 강제 + 문장별 인용

STEP 7

답변 검증·분기

근거 일치·신뢰도 판정 → 통과 시 답변 / 미달 시 제한 안내

2.3 출처 연계 & 환각 최소화

- **출처 카드 UI** — 답변 하단 「참고 자료」에 문서명·발행기관·발행연도·원문 링크·관련 페이지를 표기하고, 문장별 각주형 인용 번호를 부착합니다.
- **환각 최소화 5대 전략** — 폐쇄형 지식베이스, 근거 강제 생성, 생성 후 검증, 낮은 온도(temperature), 골든 평가셋 기반 충실성 상시 측정.
- **답변 제한·보완 루프** — 공식자료로 확인이 어려운 질의는 표준 안내문으로 안내하고, 비식별 처리 후 CMS 검토큐에 자동 등록 → 승인 시 신규 지식자료로 반영합니다.

2.4 지식자료·CMS 연동 및 개인정보·보안

- **CMS 관리** — 지식자료 등록·수정·삭제·분류, 공개/기간한정/비공개 공개범위 설정, 출처 메타데이터 필수 입력, 작성→검토→발주기관 승인→반영 워크플로우.
- **인덱싱 파이프라인** — 공공기관 자료 대부분인 **한글(HWP·HWPX) 문서 직접 파싱** 지원, 파싱→청킹→임베딩→인덱스 업서트를 이벤트 기반으로 자동화(변경 수 분 내 반영).
- **개인정보 보호** — 첫 화면 상시 고지, PII 이중 탐지(패턴+NER) 후 **원본 질의문 미저장** 원칙, 비식별 로그만 보관, 보관기간 경과 시 자동 파기.
- **CSAP 보안** — 공공존 VPC, 웹/관리자 서브넷 분리, Multi-AZ 이중화·오토스케일, 프롬프트 주입(Prompt Injection) 대응.

운영서버는 클라우드형(옵션 1) 과 독립서버 임대형(옵션 2) 두 가지로 산정했습니다. 아래 금액은 견적서 (PIBS202606-043) 기준 12개월 운영 비용입니다.

옵션 1 · 클라우드형

713만원 / 년

고정 서버 + 서버리스 AI + 피크 대응을 모두 포함. 트래픽 급증에 자동 확장.

확장성·행사 대응 우수

옵션 2 · 독립서버 임대형

308만원 / 년

Dell R640 물리서버 임대 + 세팅. 고정 비용 최저. (AI API 사용료 별도)

초기·고정비용 최저

3.1 사양 비교

구분	옵션 1 — 클라우드형	옵션 2 — 독립서버 임대형
기본 서버	t3.medium (2 vCPU / 4 GiB)	Dell R640 물리서버
CPU	2 vCPU (오토스케일)	Xeon Gold 6138 20 Core (2.0 GHz)
메모리	4 GiB (확장 가능)	DDR4 RDIMM 16 GB
스토리지	객체 스토리지(S3) 종량제	SSD 500GB × 2 (RAID 1, 가용 500GB)
AI/백엔드	Lambda + API Gateway, DynamoDB On-Demand, S3 + CloudFront, Gemini Flash API	서버 내 자체 구동 (AI API 사용료 별도)
확장성	피크 시 자동 확장, 요청 없으면 과금 최소	고정 사양(수동 증설)

* 옵션 1은 견적서상 AWS 서버리스 + Gemini Flash 조합을 기준으로 산정되었습니다. CSAP·데이터 주권 요건과의 정합성은 4장 및 하단 유의사항 참조.

3.2 비용 상세 (12개월)

옵션	항목	USD	원화(₩1,506/\$)
옵션 1 클라우드형	클라우드 서버 고정 운영 (t3.medium)	\$1,080	약 163만원
	평상시 서버리스 운영 (\$54 × 12개월)	\$648	약 98만원
	피크 추가분 (\$250 × 12회)	\$3,000	약 452만원
	옵션 1 합계	\$4,728	약 713만원
옵션 2 독립서버	Dell R640 임대 (203,500원/월 × 12, VAT 포함)	—	약 244만원
	서버 세팅 비용 (1회성)	—	약 64만원
	옵션 2 합계	—	약 308만원

* 옵션 2는 하드웨어 임대·세팅 비용이며, 글로벌 상용 AI API를 사용할 경우 API 사용료가 추가됩니다. 도메인 연 \$15(약 2.3만원) 별도, SSL(ACM) 무료.

유의 옵션 선택 기준

옵션 2(308만원) 는 고정비가 가장 낮지만 하드웨어 임대만 포함하므로, AI 인터뷰 사용량이 많으면 별도 API 비용이 더해져 총액이 옵션 1에 근접할 수 있습니다. **옵션 1(713만원)** 은 피크(행사기) 자동 확장과 AI 비용까지 포함한 총소요액입니다. 상시 부하가 낮고 예측 가능하면 옵션 2가, 행사 집중·트래픽 변동이 크면 옵션 1이 유리합니다.

AI 모델은 **답변 생성용 LLM** 과 **검색용 임베딩·리랭커** 로 나뉩니다. 선정 요건은 ① CSAP 공공존 내 데이터 처리(외부 유출 차단), ② 한국어 품질, ③ 비용·운영 부담입니다.

4.1 답변 생성 LLM 후보 비교

구분	A. 공공 클라우드 LLM API	B. 자체 호스팅 sLLM	C. 글로벌 상용 API
예시	하이퍼클로바X (네이버클라우드 공공) 등	공개 가중치 한국어 경량 LLM	Gemini Flash, Claude 등
데이터 처리	공공 클라우드 존 내부, 학습 미 활용 계약	자체 VPC 내부만, 외부 전송 없음	해외 리전 가능성·학습활용 정책 확인 필요
한국어 품질	우수	양호(모델 의존)	우수
비용 구조	호출량 과금	GPU 인프라 + 운영 인력	호출량 과금(단가 낮음)
CSAP 정합	적합	적합	착수 시 검토 필요
비고	구축 신속, GPU 부담 없음	완전 통제, 트래픽 증가 시 비용 예측 용이	견적서(옵션1)의 기본 채택 모델

4.2 검색용 모델 (공통)

- **임베딩 — BGE-M3 (자체 호스팅)** : 한국어 검색 벤치마크 상위, 의미+키워드 하이브리드를 단일 모델로 지원, 외부 API 미사용으로 데이터 외부 전송 차단.
- **리랭커 — Cross-Encoder (자체 호스팅)** : 1차 검색 결과를 질의와 정밀 대조하여 근거 문단만 선별.
- 임베딩·리랭커는 LLM 옵션(A/B/C)과 무관하게 **공공존 내 자체 구동을 기본**으로 하여 지식자료·질의 데이터의 외부 전송을 차단합니다.

권고 모델 구성 권고안

발주기관의 CSAP·데이터 주권 요건이 확정 조건이라면 **옵션 A(공공 클라우드 LLM)**를 기본안으로 권고합니다. 보안 요건 강화나 트래픽 급증 시에는 옵션 B(자체 sLLM)로 전환할 수 있도록, 아키텍처에 **모델 추상화 계층**을 두어 운영 중 무중단 전환·신규 모델 도입이 가능하게 설계합니다.

검색 계층(BGE-M3 + Cross-Encoder)은 옵션과 무관하게 자체 호스팅으로 고정합니다.

확인 필요 견적서의 Gemini Flash 채택 관련

운영서버 견적서(옵션 1)는 비용·속도 측면에서 유리한 Gemini Flash API(글로벌 상용, 옵션 C)를 기준으로 산정되었습니다. 다만 이는 개발계획서의 CSAP 공공존·국산 LLM 방향과 상이하므로, 어떤 LLM을 채택할지는 착수 단계에서 발주기관의 보안 요건(데이터 처리 위치·학습 활용 여부)을 확인하여 확정해야 합니다. 모델 추상화 설계로 인해 확정 결과에 따라 A/C 어느 쪽으로도 유연하게 대응 가능합니다.

아래 시나리오는 견적서 산정 전제를 기준으로 한 **추정치**이며, 실제 대화 길이·이용 패턴에 따라 변동합니다. (클라우드 형 옵션 1 기준)

5.1 산정 전제

운영 기간	최대 동시 이용자	피크	적용 환율
12개월	100명	월 1회 · 100명 × 6h	₩1,506 / \$1

5.2 운영 상태별 월 비용

운영 상태	설명	월 USD	월 원화	연 환산
고정 인프라	t3.medium 상시 가동 (기본 베이스)	\$90	약 13.6만원	약 163만원
평상시	피크 없는 달, AI 부하 낮음	\$54	약 8.1만원	약 98만원
피크 포함	행사·개막 등 피크 주간 포함	\$250	약 37.7만원	약 452만원*
대규모 행사기	피크가 월 다회 발생 (개·폐막 집중)	\$250↑	약 37.7만원↑	별도 산정

* 견적서는 피크 추가분(\$250)을 12회 반영하여 연 약 452만원으로 산정. 고정 인프라·평상시·피크를 합산한 연 총액이 약 713만원(3.2 참조).

5.3 이용자당 원가 추정

피크가 포함된 달의 서버리스 증가분(약 \$196 = \$250 - \$54)이 AI 인터뷰 처리에 대응합니다. 피크 주간 처리 인원을 기준으로 하면 **AI 인터뷰 1건당 원가는 대략 수백 원 ~ 3천 원 수준**으로 추정됩니다(대화 길이에 좌우). 상시 이용은 요청량에 비례하는 종량제라 유휴 시 과금이 최소화됩니다.

변수 비용에 영향을 주는 요인

AI API 사용료가 최대 변수입니다 — 대화 길이에 따라 월 ±\$20 편차가 발생할 수 있습니다. 그 밖에 Lambda 콜드스타트(평상시 첫 요청 1~2초 지연), DynamoDB On-Demand 실사용량 변동, 도메인 연 \$15(약 2.3만원, SSL 무료)가 있습니다. 위 수치는 모두 실측 사용량에 따라 변동하는 **추정치**입니다.

- **구현** — CSAP 공공존 기반 지식기반형 RAG 챗봇(출처 연계·환각 최소화·HWP 파싱·개인정보 비식별)로 구축합니다.
- **서버** — 행사 트래픽 변동이 크면 클라우드형(옵션 1, 약 713만원/년), 상시 부하가 낮고 예측 가능하면 독립서버형(옵션 2, 약 308만원/년 + AI API 별도)을 권고합니다.
- **AI 모델** — CSAP 요건 확정 시 공공 클라우드 LLM(옵션 A)을 기본으로, 모델 추상화로 자체 sLLM(B)·상용 API(C) 전환 여지를 확보합니다. 검색 계층(BGE-M3)은 자체 호스팅 고정.
- **비용** — 클라우드형은 AI 사용량이 최대 변수이므로, 착수 시 골든 평가셋·부하시험으로 실측 후 예산을 확정합니다.

다음 단계 착수 시 확정 항목

① LLM 옵션(A/B/C) 및 서버 옵션(1/2) 최종 선택 · ② 개인정보·질의 로그 보관정책(예: 1년) 협의 · ③ 지식자료 목록·공개범위 확정 · ④ 검수 기준(성능 목표: 근거 일치율 95%↑, 출처 정확도 98%↑, 평균 응답 5초 이내, 가용성 99.5%↑) 합의.